

# **Redução de tempo de espera no descarregamento de grãos: um estudo de caso com monitoramento de pátios de armazéns através de câmeras**

**Alisson Gean Buiarski, Benevid Felix da Silva**

Curso de Sistemas de Informação  
Universidade do Estado de Mato Grosso (UNEMAT)  
Av. dos Ingás, 3001 - Jardim Imperial, Sinop - MT, 78555-000

`alisson.gean@unemat.br, benevid@unemat.br`

## **Abstract**

This article proposes a solution to optimize the unloading logistics in grain warehouses by utilizing security camera images and a YOLO-based neural network. Through this system, it is possible to real-time identify the number of trucks in the waiting yard and provide information to rural producers, improving communication between them and the warehouses. This approach aims to reduce queues and delays in the unloading process, ensuring the quality of stored grains. Simulation results indicate that this solution can be effective in optimizing the process, providing more efficient management of delivery logistics in grain warehouses. This leads to financial and operational benefits for producers and contributes to reducing losses in grain quality.

## **Resumo**

Este artigo propõe uma solução para otimizar a logística de descarregamento em armazéns de grãos, utilizando imagens de câmeras de segurança e uma rede neural baseada em YOLO. Através desse sistema, é possível identificar o número de caminhões no pátio de espera em tempo real e fornecer informações aos produtores rurais, melhorando a comunicação entre eles e os armazéns. Essa abordagem visa reduzir filas e atrasos no processo de descarga, garantindo a qualidade dos grãos armazenados. Os resultados das simulações indicam que essa solução pode ser eficaz na otimização do processo, proporcionando uma gestão mais eficiente da logística de entrega nos armazéns de grãos. Isso resulta em benefícios financeiros e operacionais para os produtores e contribui para a redução de perdas na qualidade dos grãos.

## 1.0 Introdução

A armazenagem de grãos dentro do processo de produção agrícola contribui para reduzir as perdas e preservar a qualidade dos grãos, além de ter como objetivo suprir a demanda durante a entressafra ou aguardar por preços melhores em um momento oportuno Sauer, (1992). Segundo Biagi et al. (2002) e Frederico (2011), o armazém desempenha diversas funções, desde a conservação da qualidade e controle de perdas até o suporte às políticas de segurança alimentar, estoques reguladores, logística de produção e transporte. Essa prática de armazenagem de grãos também desempenha um papel importante no equilíbrio entre oferta e demanda, permitindo atender a uma demanda constante através de uma oferta sazonal e sujeita a variações determinadas pelas safras e entressafras.

Um armazém de grãos possui muitos desafios, como atender a alta demanda dos produtores, manter a qualidade dos grãos armazenados, a gestão de filas no descarregamento, entre outros. Acerca deste último, impacta não somente a gestão dos armazéns, mas também os produtores, que precisam gerenciar o envio dos caminhões para depositar a safra. O atraso no descarregamento pode gerar longas filas de espera e grandes atrasos no processo de descarga, levando muitas vezes a perdas financeiras devido à deterioração da qualidade dos grãos que ainda estão nos caminhões à espera para fazer a descarga.

A comunicação entre os armazéns de grãos e os produtores é fundamental para garantir uma eficiente logística de entrega. No entanto, muitos ainda utilizam métodos ultrapassados, como ligações telefônicas e aplicativos de mensagens para realizar essa tarefa. Como resultado, esses armazéns podem receber mais de 200 ligações por dia, tornando o processo lento e pouco prático.

Existem trabalhos que aplicam algumas abordagens para monitorar e reduzir as filas, tais como o estudo de caso Lahan (2019), que apresenta uma análise do processo que ocorre em um armazém distribuidor de produtos, que encontra dificuldades em seus processos, incluindo a parte de logística de descarregamento e carregamento dos veículos, no estudo de caso observa-se que métodos de pesquisa em simulação de software são aplicados para amenizar as filas e otimizar o processo por completo.

Este trabalho propõe uma solução para o problema da logística de descarregamento, voltada ao produtor rural, que utiliza as imagens das câmeras de segurança instaladas nos pátios dos armazéns para identificar a ocupação do local de espera dos caminhões, através da aplicação de uma rede neural utilizando a ferramenta YOLO. A rede é capaz de contabilizar o número de caminhões no pátio e fornecer informações em tempo real sobre a quantidade de caminhões no pátio de espera, repassando essas informações ao produtor

rural. Através das simulações realizadas, o trabalho deixa indícios de que é possível otimizar o processo de descarga nos armazéns utilizando esta abordagem.

Uma vez que o controle dos pátios dos armazéns é realizado em alguns casos, mas somente de forma interna ao próprio empreendimento, onde por exemplo utilizam de softwares, para o controle de todo o armazém e para controle de chegada dos veículos, entrada, pesagem e saída, porém sem repasse ou acesso a essas informações aos produtores, que por sua vez não tem interesse nessa abordagem de controle.

## **2.0 Trabalhos Relacionados**

Na literatura especializada existem alguns diversos trabalhos que abordam a detecção de objetos em imagens, em diferentes aplicações, como por exemplo, Albuquerque (2022) estuda e utilizam a detecção por imagens de castas de abelhas melíferas de forma automatizada pela ferramenta YOLO, assim tendo objetivo de diferenciar entre operárias e zangões, obtendo resultados com valores de precisão e recall acima de 85%, indicando a eficácia da técnica para a apicultura de precisão.

Souza (2021), em sua pesquisa, demonstra alguns métodos de visão computacional que são apresentados, onde em seu objetivo tem como foco avaliar o desempenho de diferentes versões do algoritmo de aprendizado profundo YOLO para a detecção de placas de veículos, com o objetivo de proteger informações pessoais. As principais contribuições deste trabalho são a utilização de um algoritmo de deep learning como abordagem para automatizar uma atividade de proteção de dados e a customização de um dos algoritmos para proteção de dados pessoais.

Cordeiro (2019), aborda a importância da detecção e contagem de pessoas em diferentes aplicações, como segurança e otimização do transporte público, e os desafios enfrentados nessa tarefa, como oclusão pesada e baixa resolução. O autor destaca o uso de redes neurais convolucionais na detecção de objetos e propõe a implementação de um aplicativo para contagem de pessoas por meio da detecção e rastreamento, com o objetivo de otimizar a carga computacional.

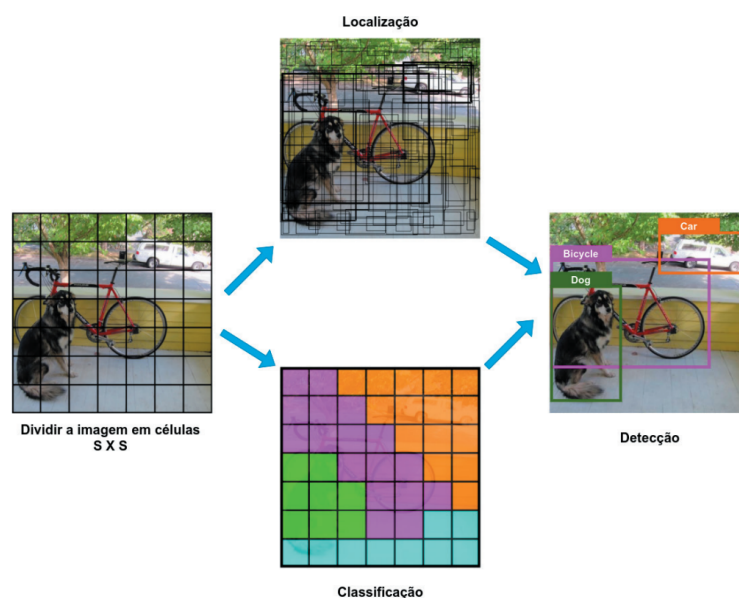
Já na dissertação de mestrado de Cavallari (2021), é apresentado o estudo logístico do recebimento da soja e carregamento do milho em unidades de beneficiamento. Com o objetivo de avaliar a eficiência do escoamento interno de caminhões em condições de pico de safra. O estudo utilizou análise estatística e simulação de processos produtivos, além do diagrama de Ishikawa para identificar os principais problemas encontrados em cada unidade e suas possíveis causas. O estudo permitiu identificar oportunidades de melhorias

### 3.0 YoLO

YOLO, que é uma rede neural profunda que se destaca por combinar desempenho e precisão em um sistema de detecção rápida e eficiente segundo Redmon (2016). A sigla "You Only Look Once" indica que a rede processa uma imagem completa apenas uma vez, ao contrário de outros sistemas que dividem a imagem em regiões menores e processam cada uma delas separadamente. A rede utiliza um sistema de anotações para fornecer detecções precisas de objetos de interesse, incluindo sua posição e tamanho, além de atribuir um nível de confiança a cada detecção. Com seu alto desempenho e precisão, o YOLO é uma ferramenta importante em diversas aplicações de detecção de objetos em tempo real.

A detecção de objetos é composta por dois processos distintos: a classificação e a localização. Segundo Forsyth e Ponce (2012), algoritmos classificadores são capazes de atribuir um rótulo a um conjunto de recursos extraídos da imagem. Já os localizadores, conforme explicado por Blaschko e Lampert (2018), são responsáveis por distinguir o objeto do plano de fundo e identificar as relações espaciais entre os objetos na imagem. A utilização conjunta da classificação e localização permite que o YOLO identifique vários objetos diferentes em uma imagem.

A arquitetura do YOLO é ilustrada na Figura .1 e envolve três etapas. Primeiramente, é aplicada uma grade  $S \times S$  sobre a imagem. Em seguida, a classificação e localização dos objetos são realizadas simultaneamente. Finalmente, a detecção é gerada com as caixas delimitadoras e rótulos correspondentes.



Fonte: Adaptado de Redmon et al (2016).

Figura 1 – Etapas de funcionamento do YOLO

## **Conjunto de dados Microsoft COCO**

Para esse artigo foi utilizado o conjunto de dados Microsoft COCO, (*Common Objects in Context*) Lin et al., (2014) que é um conjunto de dados de referência de grande escala para detecção, segmentação e legenda de objetos em imagens. O conjunto de dados contém mais de 330.000 imagens com mais de 2,5 milhões de instâncias de objetos anotados com caixas delimitadoras, segmentações de objetos e legendas de texto. As imagens são coletadas em condições do mundo real e apresentam objetos em contextos variados, como pessoas em atividades cotidianas, animais em seus habitats naturais e objetos em vários ambientes. O conjunto de dados foi construído para promover o avanço do estado-da-arte em tarefas de compreensão de imagem e foi projetado para ser usado para avaliar o desempenho de algoritmos de visão computacional em várias tarefas, como detecção de objetos, segmentação semântica e geração de legenda de imagem. O conjunto de dados Microsoft COCO e suas métricas de avaliação associadas se tornaram um padrão da indústria para avaliar algoritmos em várias tarefas de visão computacional.

## **Plataforma Google Colab**

O Colab é uma plataforma gratuita baseada em nuvem para desenvolvimento de projetos em ciência de dados, permitindo que os usuários colaborem em tempo real com outras pessoas, compartilhando e editando seus projetos em conjunto. Segundo a documentação do Google Colab (2021), ele pode ser usado para desenvolvimento de projetos de pesquisa, análise de dados e experimentação em aprendizado de máquina. Devido à sua facilidade de uso e disponibilidade gratuita. O Colab oferece acesso gratuito a GPUs e TPUs, permitindo que os usuários treinem modelos de aprendizado de máquina de forma mais rápida e eficiente. Além disso, ele também fornece acesso a uma ampla variedade de bibliotecas de código aberto e ferramentas de visualização de dados para facilitar o desenvolvimento de projetos de ciência de dados.

## **Aspectos Metodológicos**

O trabalho desenvolvido foi organizado conforme as seguintes etapas: estudo bibliográfico, escolha e adaptação de uma rede neural existente, implementação da solução em um ambiente simulado e avaliação dos resultados.

Na etapa de estudo bibliográfico, foram revisados artigos científicos, livros e outras fontes relevantes para compreender os desafios da armazenagem de grãos, as necessidades dos produtores e as tecnologias disponíveis para melhorar a logística de entrega.

Em seguida, foi escolhida uma rede neural existente que fosse adequada para o problema em questão. Dado que não havia acesso às câmeras dos armazéns devido à época sem entrega de grãos, decidiu-se utilizar uma solução baseada em dados simulados. Portanto,

a rede neural escolhida foi adaptada para receber dados sintéticos que representassem a ocupação do local de espera dos caminhões.

A implementação da solução foi realizada em um ambiente simulado, onde foram gerados dados sintéticos que representavam a ocupação do pátio de espera dos caminhões. Esses dados foram alimentados na rede neural adaptada, permitindo que ela realizasse a contagem dos caminhões em tempo real e fornecesse informações sobre a capacidade do pátio de espera.

Por fim, foram realizadas avaliações dos resultados obtidos com a implementação da solução em ambiente simulado. Foram analisadas métricas como a precisão na contagem dos caminhões e a capacidade do sistema em fornecer informações sobre a ocupação do pátio de espera. Essas avaliações permitiram verificar a eficiência da abordagem proposta e identificar possíveis melhorias ou ajustes necessários.

No geral, o trabalho desenvolvido demonstrou que a utilização de uma rede neural existente, adaptada para receber dados sintéticos, pode oferecer uma solução mais eficiente e prática para a gestão da ocupação do local de espera dos caminhões nos armazéns de grãos. Apesar de não ter sido possível utilizar dados reais das câmeras de segurança devido à época sem entrega de grãos, a abordagem simulada mostrou indícios de que é possível otimizar o processo de descarga nos armazéns com base nessa solução.

### **Sistema de Monitoramento de Pátio de Armazéns**

O sistema de monitoramento visa apresentar o sistema completo para monitoramento de pátio de caminhões, conforme ilustra a figura 4. Neste sistema, realizamos os testes para validar a identificação dos caminhões no pátio utilizando o YoLO. Os testes indicam a viabilidade de melhorar e implantar um sistema completo que possa atender os produtores rurais. O item 6 da figura 4, refere-se aos testes realizados. Os demais itens fazem parte do projeto, e ainda estão em desenvolvimento como parte de um negócio.

A estrutura do sistema é composta pelos seguintes aspectos:

1. Aplicativo intuitivo: Desenvolvimento de um aplicativo com interface simples e intuitiva para os produtores. Listagem dos armazéns parceiros e seus dados, incluindo a quantidade estimada de veículos aguardando descarga.
2. Servidor para processamento: Implementação de um servidor capaz de receber as requisições do aplicativo. Processamento das imagens coletadas e análise utilizando a tecnologia YoLO para identificar e contar os caminhões no pátio de espera.
3. Utilização de câmeras de segurança: Consideração da instalação de câmeras de segurança no pátio do armazém, seguindo as diretrizes legais aplicáveis.

- Utilização das câmeras de segurança existentes, caso estejam disponíveis e atendam aos requisitos de qualidade e posicionamento.
4. Coleta e envio de imagens: Coleta das imagens do pátio de caminhões por meio das câmeras de segurança instaladas ou existentes. Envio das imagens coletadas para o servidor para serem processadas e analisadas.
  5. Processamento e análise: Utilização da tecnologia YOLO no servidor para processar as imagens e identificar os caminhões presentes no pátio de espera. Análise das imagens para obter informações atualizadas sobre a ocupação do local.
  6. Retorno dos resultados ao aplicativo: Envio dos resultados da contagem de veículos do servidor de volta para o aplicativo. Exibição dos resultados atualizados no aplicativo, permitindo aos produtores acompanharem a ocupação do pátio de caminhões em tempo real.
  7. Informações para os produtores: Disponibilização das análises e resultados no aplicativo para que os produtores possam acessar informações detalhadas sobre a ocupação do pátio de caminhões. Apresentação de dados relevantes, como disponibilidade de vagas de descarga e estimativa de tempo de espera, auxiliando os produtores na tomada de decisões.

O presente estudo do artigo se baseia na premissa de aplicação em armazéns parceiros no qual somente cedem o espaço, internet e energia a serem utilizados, para que o equipamento que é composto por uma câmera de segurança seja instalado em um local propício com ampla visão de seu pátio de espera. Não tendo mensalidades ao armazenista, assim repassando ao produtor que é o de maior interesse.

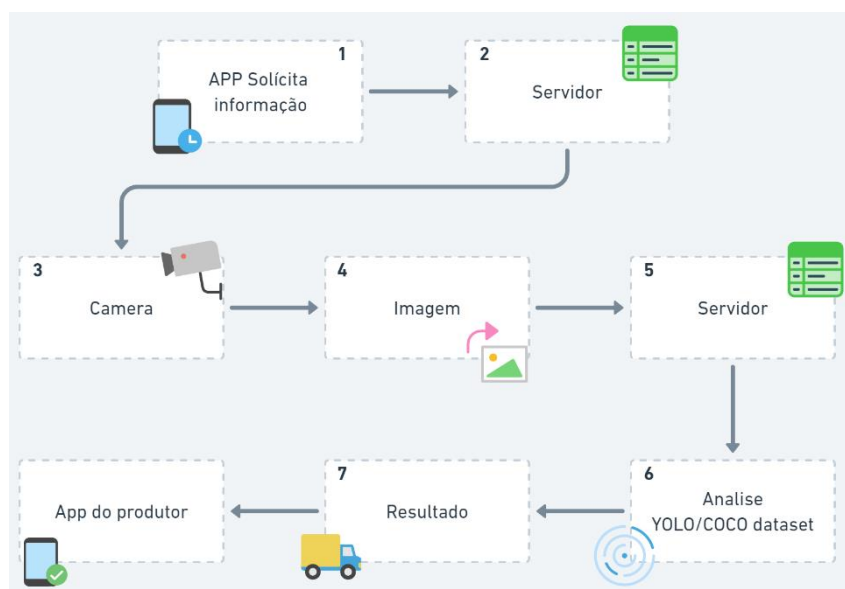


Figura 2 – Diagrama do processo sistêmico a ser desenvolvido.

## **Estudo de caso - Análise YOLO/COCO Dataset**

O presente estudo teve como objetivo analisar imagens capturadas na região agrícola e industrial de Sinop, localizada no estado do Mato Grosso, Brasil. As imagens utilizadas foram de autoria própria, garantindo a originalidade e a integridade dos dados coletados.

Uma vez feito a captação das imagens foram submetidas ao processo de análise e processamento que consiste em um ambiente onde é realizado e utilizando o *Google Colab* como plataforma para as análises com a utilização do código para tal operação, sendo realizado configurações para utilização da *GPU (Graphics Processing Unit)* disponível no *Google Colab*, assim ficando o processamento mais rápido.

Com a utilização dos comandos `!git clone https://github.com/AlexeyAB/darknet` conseguimos realizar a cópia do repositório *darknet* que é usada como base para a realização das análises das imagens, onde se encontra já previamente configurados o ambiente necessário da rede neural convolucional que será utilizada, assim como o conjunto de pesos pré-treinados que utilizam o *dataset COCO*, que por sua vez é usado para realizar detecção dos veículos com base no banco de imagens existente.

Com o ambiente previamente pronto, é possível realizar alguns pequenos ajustes e adaptações para atender as necessidades propostas no estudo como habilitar o *OPENCV "Open Source Computer Vision Library"* (Biblioteca de Visão Computacional de Código Aberto), que fornece um conjunto abrangente de funções e algoritmos que abrangem uma ampla gama de tarefas de processamento de imagem e visão computacional, como detecção de objetos, reconhecimento facial, rastreamento de movimento, calibração de câmera, segmentação de imagem, entre outros. E o *CUDNN (CUDA Deep Neural Network library)* que é uma biblioteca desenvolvida pela NVIDIA que fornece aceleração de hardware para operações de redes neurais profundas.

Após a conclusão das etapas de configuração e preparação do ambiente, as imagens foram depositadas em um local específico no repositório que efetuamos a cópia, um ambiente seguro e especializado para análises de imagens. Em seguida, foi executado o comando necessário para iniciar o processamento e análise das imagens. Esse processo consiste na utilização da rede neural convolucional presente no repositório *darknet*, que já possui configurações e pesos pré-treinados usando o *dataset COCO*, o qual permite a detecção de veículos com base nas imagens disponíveis. O uso da GPU disponível no *Google Colab* otimiza o processamento, garantindo maior velocidade e eficiência na análise das imagens.

## **Resultados e Discussão**

No total, foram analisadas 20 imagens selecionadas de um grande número capturadas, que retratam uma situação desafiadora em relação à alocação adequada dos veículos. Em



grande parte das imagens, observou-se a presença de carretas estacionadas em pátios de espera, aguardando o momento de descarregamento ou carregamento nos armazéns.

Abaixo, podemos observar algumas das imagens coletadas, analisadas e processadas pela ferramenta que é a base do estudo apresentado.



*Figura 3 - Imagem processada as margens da BR 163 Sinop – MT.*



*Figura 4 - Imagem processada as margens da BR 163 Sinop – MT.*



Figura 5 - Imagem processada as margens da BR 163 Sinop – MT.



Figura 6 - Imagem do estacionamento capturada da câmera de segurança de um armazém.


A assertividade dos dados obtidos por meio das imagens foi avaliada com base em critérios específicos, conforme apresentado na *tabela 01*. Os resultados revelaram uma alta taxa de concordância, reforçando a representatividade das imagens e sua relevância para o estudo em questão. Sendo feita a análise da assertividade com a seguinte formula:

$$porcentagem\_acertividade = (veiculos\_identificadas - falsos\_negativos - falsos\_positivos) / numero\_total\_veiculos * 100$$

Imagens	Carretas Veículos	Contagem	Falsos Positivo	Falso Negativo	Assertividade %
Analise 01	5	6	1	0	100
Analise 02	5	4	0	1	60
Analise 03	5	5	0	0	100
Analise 04	6	5	1	2	33,33333333
Analise 05	11	9	0	2	63,63636364
Analise 06	7	6	0	1	71,42857143
Analise 07	8	8	0	0	100
Analise 08	6	5	0	1	66,66666667
Analise 09	7	5	0	2	42,85714286
Analise 10	5	4	0	0	80
Analise 11	6	6	0	0	100
Analise 12	8	8	0	0	100
Analise 13	12	12	1	1	83,33333333
Analise 14	15	14	1	2	73,33333333
Analise 15	7	6	0	0	85,71428571
Analise 16	9	9	0	0	100
Analise 17	10	9	0	0	90
Analise 18	7	6	0	1	71,42857143
Analise 19	12	11	0	2	75
Analise 20	8	7	0	1	75
Totais	159	145	4	16	78,6163522

*Tabela 1 – Dados coletados das análises das imagens processadas*

Um dos maiores desafios em análise das imagens são os casos de oclusão, no contexto de detecção de objetos, refere-se à situação em que um objeto é parcialmente ou completamente obscurecido por outro objeto na cena. No caso de carretas posicionadas uma na frente da outra, a oclusão ocorre quando uma carreta está bloqueando parcialmente ou totalmente a visão de outra carreta. Ocasionalmente assim os falsos positivos ou falsos negativos, sendo falso positivo quando uma carreta é erroneamente detectada quando não está presente, enquanto falso negativo é quando uma carreta real não é detectada corretamente.



*Figura 7 – Imagem processada com caso de oclusão.*

Na *Figura 7* teremos uma das análises realizadas onde podemos observar um caso de oclusão acontecendo com o processamento da imagem finalizado, fazendo assim, gerar um falso negativo, que por sua vez pode ser aperfeiçoado e corrigido com o treinamento da rede neural, levando em conta novos pesos e parâmetros que podem ser treinados. Levando assim os índices de assertividade e confiança serem elevados.

Com essas informações, os produtores poderão tomar decisões estratégicas sobre onde enviar seus caminhões para descarregar e evitar filas desnecessárias, minimizando o tempo de espera e aumentando a eficiência do processo de descarga. Além disso, a tecnologia de monitoramento pode ser replicada em vários armazéns e pátios, proporcionando uma gestão mais inteligente e integrada dos armazéns de grãos em todo o país.

## **Conclusão**

A principal contribuição e originalidade desse artigo é um método para otimizar a tomada de decisão dos produtores para onde devem enviar seus caminhões e carretas para fazer a descarga do produto colhido, através de análise de imagem dos pátios dos armazéns com resultados de quantias de veículos lá aguardando o descarregamento. Nessa perspectiva, entende-se que a solução apresentada é inédita e expressiva, uma vez que foi introduzida uma abordagem baseada em dados empíricos. O uso do código aberto Darknet e detector YOLO, com o dataset COCO, conhecidos pela alta velocidade de inferência, revelou-se uma boa estratégia e base para um sistema de logística mais amplo que possibilita maiores índices produtivos aos produtores.

Na qualidade de possível trabalho futuro, sugerimos o desenvolvimento e aplicação em armazéns parceiros da região e distribuição do projeto aos produtores rurais para utilização na safra, assim captando os dados e aperfeiçoando a ferramenta, buscando indicadores cada vez mais otimistas para expansão nas demais localidades e otimização dos processos que podem solucionar o problema que vem se arrastando a muito tempo.

## Referências

LAHAM, N., FATEC, Z., LESTE, ROBERTO DE OLIVEIRA JR, M. AND RAMOS DE MOARAES, R. ([S.D.]). X FATECLOG -LOGÍSTICA 4.0 & A SOCIEDADE DO CONHECIMENTO REDUZINDO TEMPO DE ATENDIMENTO EM UM ARMAZÉM UTILIZANDO SIMULAÇÃO. DISPONÍVEL EM: <[HTTPS://FATECLOG.COM.BR/ANAIS/2019/REDUZINDO%20TEMPO%20DE%20ATENDIMENTO%20EM%20UM%20ARMAZ%C3%89M%20UTILIZANDO%20SIMULA%C3%87%C3%83O.PDF](https://fateclog.com.br/anaais/2019/reduzindo%20tempo%20de%20atendimento%20em%20um%20armaz%C3%89m%20utilizando%20simula%C3%87%C3%83o.pdf)>

SAUER, D.B. STORAGE OF CEREAL GRAINS AND THEIR PRODUCTS. FOURTH EDITION, ST. PAUL, MN: AACC, 1992. 615P.

REDMON, J., DIVVALA, S., GIRSHICK, R., & FARHADI, A. (2016). YOU ONLY LOOK ONCE: UNIFIED, REAL-TIME OBJECT DETECTION. IN PROCEEDINGS OF THE IEEE CONFERENCE ON COMPUTER VISION AND PATTERN RECOGNITION (PP. 779-788).

LIN, T.-Y., MAIRE, M., BELONGIE, S., HAYS, J., PERONA, P., RAMANAN, D., ... ZITNICK, C. L. (2014). MICROSOFT COCO: COMMON OBJECTS IN CONTEXT. LECTURE NOTES IN COMPUTER SCIENCE, 8693, 740-755. DOI: 10.1007/978-3-319-10602-1\_48

GOOGLE. GOOGLE COLABORATORY. DISPONÍVEL EM: [HTTPS://COLAB.RESEARCH.GOOGLE.COM/](https://colab.research.google.com/). ACESSO EM: 12/05/2023.

FORSYTH, DAVID A.; PONCE, JEAN. COMPUTER VISION: A MODERN APPROACH. 2. ED. NEW JERSEY: PEARSON EDUCATION, 2012. P. 761p

BLASCHKO, MATTHEW B.; LAMPERT, CHRISTOPH H.. LEARNING TO LOCALIZE OBJECTS WITH STRUCTURED OUTPUT REGRESSION. LECTURE NOTES IN COMPUTER SCIENCE, [S.L.], P. 2-15, 2008. SPRINGER BERLIN HEIDELBERG. [https://link.springer.com/chapter/10.1007/978-3-540-88682-2\\_2](https://link.springer.com/chapter/10.1007/978-3-540-88682-2_2)

BIAGI, J. D.; BERTOL, R.; CARNEIRO, M. C. ARMAZÉNS EM UNIDADES CENTRAIS DE ARMAZENAMENTO. IN: LORINI, I.; MIIKE, L. H.; SCUSSEL, V. M. (ED.). ARMAZENAGEM DE GRÃOS.CAMPINAS, SP: IBG, 2002. P. 157–161.

FREDERICO, S. THE MODERN AGRICULTURAL FRONTIER AND LOGISTICS: THE IMPORTANCE OF THE SOYBEAN AND GRAIN STORAGE SYSTEM IN BRAZIL. TERRAE, V. 8, N. 1-2, P. 26–34, 2011.

GOOGLE COLAB. (2021). WELCOME TO COLABORATORY. RECUPERADO EM 09 DE MAIO DE 2023, DE [HTTPS://COLAB.RESEARCH.GOOGLE.COM](https://colab.research.google.com).